De la détection de polypes à la segmentation de tumeurs pancréatiques : limites des détecteurs *open-vocabulary* et rôle d'un classifieur appris en aval

Morad Bel-Melih[1*], **Paul B.**[1]
[1]Polytechnique Montréal, Cours INF8225 – Projet 2026
morad.bel-melih@polymtl.ca, paul.b@polymtl.ca

Abstract

Nous étudions une chaîne de segmentation faiblement supervisée qui combine un détecteur *open-vocabulary* (*Grounding DINO*) et un segmenteur *promptable* (*MedSAM*). Cette chaîne atteint un DICE de 0,95 sur *Kvasir-SEG* en mode oracle, ce qui valide le principe d'une segmentation pilotée par boîtes textuelles. Lorsque nous appliquons la même architecture aux tumeurs pancréatiques du *Medical Segmentation Decathlon*, la spécificité s'effondre à 0,17 à cause des hallucinations massives du détecteur sur les coupes saines. Nous documentons ensuite quatre stratégies successives pour restaurer cette spécificité, motivées par nos observations expérimentales : un agent multimodal de vérification (*Gemini*), une porte anatomique fondée sur un U-Net du pancréas, une cascade spatiale pancréas→tumeur, et enfin un classifieur ResNet-18 d'ensemble entraîné sur les négatifs durs produits par *Grounding DINO*. Cette dernière stratégie porte la spécificité à 0,74 sans effondrer la sensibilité, et illustre que le signal de texture local capté par un classifieur appris est complémentaire au signal *open-vocabulary* du détecteur.

1 Introduction

L'apprentissage profond a profondément modifié la segmentation d'images médicales. Les architectures spécialisées comme *U-Net* [Ronneberger *et al.*, 2015] puis *nnU-Net* [Isensee *et al.*, 2021] dominent les *benchmarks* lorsqu'un volume suffisant de masques pixel précis est disponible. Cette exigence reste un frein opérationnel, et plusieurs travaux récents proposent de la contourner en composant deux modèles de fondation. *Segment Anything* [Kirillov *et al.*, 2023] et son adaptation médicale *MedSAM* [Ma *et al.*, 2024] produisent un masque à partir d'un *prompt* géométrique, tandis que les détecteurs *open-vocabulary* comme *Grounding DINO* [Liu *et al.*, 2024] génèrent ce *prompt* à partir d'une simple chaîne de caractères. La promesse est séduisante : aucune annotation pixel n'est requise au moment de l'inférence, seulement le nom de la classe d'intérêt.

Notre projet éprouve cette chaîne sur deux problèmes de difficulté contrastée. Nous vérifions d'abord son comportement sur *Kvasir-SEG*, un *benchmark* de polypes coliques où les objets présentent un fort contraste visuel et des contours nets. Nous l'appliquons ensuite aux tumeurs pancréatiques 2D extraites du *Medical Segmentation Decathlon* [Antonelli *et al.*, 2022], un cas notoirement difficile où la tumeur partage la texture du parenchyme environnant. Le passage du premier au second domaine fait apparaître un mode d'échec spécifique, l'hallucination massive de *DINO* sur les coupes saines, qui mène à une spécificité proche du hasard. La majeure partie de notre démarche consiste alors à identifier la source de ce mode d'échec et à tester quatre mécanismes de correction de complexité croissante. Le pipeline final, qui ajoute un classifieur ResNet-18 d'ensemble [He *et al.*, 2016] en garde-fou de second étage, restaure une spécificité exploitable. Le code et les données préparées sont publiés à https://github.com/moradBMH/INF8225_Projet.

2 Travaux Antérieurs

La segmentation pancréatique spécialisée a été étudiée intensivement ; Zhou *et al.* [2017] introduisent un *fixed-point model* qui raffine itérativement la prédiction de l'organe, et Zhu *et al.* [2019] ajoutent une cascade multi-échelle pour le dépistage des adénocarcinomes ductaux. Ces approches exigent toutefois un volume conséquent de masques pixel-précis 3D, contrainte que *nnU-Net* [Isensee *et al.*, 2021] a optimisée mais sans la lever.

L'arrivée de *SAM* [Kirillov *et al.*, 2023] a changé la donne en proposant un segmenteur généraliste piloté par un *prompt* géométrique. *MedSAM* [Ma *et al.*, 2024] spécialise ce modèle sur 1,5 M de paires image/masque médicales et obtient des performances compétitives sur de nombreuses modalités. La question reste de savoir comment fournir cette boîte automatiquement, et *Grounding DINO* [Liu *et al.*, 2024] y répond en alignant un encodeur visuel DINO [Caron *et al.*, 2021] avec un encodeur textuel BERT [Devlin *et al.*, 2019]. Plusieurs publications récentes assemblent ces deux composants pour des *benchmarks* médicaux, mais peu évaluent honnêtement leur spécificité sur des images sans la classe cible.

L'utilisation d'agents multimodaux pour raffiner les prédictions visuelles constitue une famille émergente de techniques inspirées du *Chain-of-Thought* [Wei *et al.*, 2022]. Plusieurs travaux interrogent un LLM multimodal comme

*Auteur de contact

Gemini [Team, 2024] à propos d'une région candidate. Notre tentative dans ce sens, documentée en section 5.3, éclaire les limites pratiques de cette approche dans un contexte radiologique.

3 Approche Théorique

3.1 Principe d'une segmentation *promptée*

MedSAM utilise l'architecture *ViT-B* de *SAM* et produit un masque $\hat{\boldsymbol{M}}$ en moins de 50 ms par image, conditionnellement à une boîte $\boldsymbol{b} \in \mathbb{R}^4$ fournie en entrée. La qualité du masque dépend essentiellement de la qualité de la boîte ; toute erreur en amont se répercute directement en aval, ce qui fait du détecteur le point critique du pipeline.

Grounding DINO aligne un encodeur Swin-T avec un encodeur BERT par *cross-attention* bidirectionnelle. Pour une requête textuelle $\boldsymbol{q}$ et une position spatiale $\boldsymbol{p}$, il prédit un score $s(\boldsymbol{p}, \boldsymbol{q}) \in [0, 1]$ et une boîte candidate. La perte de classification est une *focal loss* [Lin *et al.*, 2017] avec $\gamma = 2{,}0$ et $\alpha = 0{,}25$, qui atténue le poids des nombreux ancres faciles. La procédure d'échantillonnage *RandomSamplingNegPos* introduit des chaînes *distractor* pendant l'entraînement, ce qui permet en principe au modèle d'apprendre à ne rien activer en l'absence de la classe cible.

3.2 Apprentissage d'un *prior* anatomique

Pour fournir une région d'intérêt anatomique, nous entraînons un *U-Net* [Ronneberger *et al.*, 2015] à quatre niveaux ($\sim$1,9 M paramètres) sur le label `1` (pancréas) du MSD. Comme cette porte doit avoir une sensibilité élevée pour ne pas masquer une vraie tumeur, nous adoptons une perte de Tversky [Salehi *et al.*, 2017] qui pénalise davantage les faux négatifs que les faux positifs,

$$\mathcal{L}_{\text{Tv}} = 1 - \frac{TP}{TP + \alpha\, FP + \beta\, FN}, \tag{1}$$

avec $\alpha = 0{,}3$ et $\beta = 0{,}7$. Le masque prédit est dilaté de 35 px pour absorber les erreurs de contour.

3.3 Classifieur appris en second étage

Lorsque les filtres spatiaux et sémantiques se révèlent insuffisants (section 5), nous ajoutons un classifieur appris qui juge chaque candidat localement. Concrètement, un *crop* 224×224 autour de chaque boîte est passé à cinq ResNet-18 [He *et al.*, 2016] initialisés avec des graines différentes. Le score *image-level* agrège les probabilités individuelles avec une pénalité sur la variance,

$$\hat{p}_{\text{ens}} = \bar{\hat{p}} - 0{,}25\, \sigma(\hat{p}), \tag{2}$$

ce qui filtre les candidats sur lesquels les modèles sont en désaccord.

4 Données et Protocole

Kvasir-SEG contient 1000 images d'endoscopie colorée accompagnées de masques de polypes et de boîtes *ground-truth*. Nous l'utilisons comme banc d'essai initial pour la chaîne *detection+segmentation*, avec un *split* 880/20/100 à la manière des publications standard.

MSD Pancreas contient 281 volumes 3D de scanners CT. Nous extrayons des coupes axiales 2D et obtenons 800 images d'entraînement (400 contenant une tumeur, 400 sans), 100 de validation et 100 de test, chacune équilibrée 50/50 entre coupes positives et négatives. Les masques sont multiclasse, avec `0` pour le fond, `1` pour le pancréas et `2` pour la tumeur. Toutes les métriques de segmentation sont calculées sur la classe tumeur, et les métriques de classification (sensibilité, spécificité, F1) sur l'image entière.

5 Expériences

Nous avons mené nos expériences en suivant une logique de complexité croissante : chaque itération répond à une faiblesse mesurée à l'étape précédente. Cette section retrace cette progression.

5.1 Validation initiale sur Kvasir-SEG

Avant d'aborder le problème pancréatique, nous vérifions que la chaîne *detection+MedSAM* fonctionne sur un cas favorable. Sur *Kvasir-SEG*, les polypes présentent un fort contraste avec la muqueuse environnante et des contours bien définis. Nous évaluons d'abord MedSAM en mode oracle, en lui fournissant directement les boîtes *ground-truth* fournies avec le dataset. La sortie atteint un DICE moyen de **0,954** sur les 1000 images, ce qui confirme que MedSAM est un segmenteur fiable lorsque la boîte est correcte. Le *fine-tuning* de *Grounding DINO* sur la classe `polyp` (configuration `polyp_config.py`) permet ensuite de fermer la boucle automatiquement, avec un mAP_{COCO} supérieur à 0,55 sur la validation. Ces résultats valident le principe et nous encouragent à porter la même architecture sur un problème plus ambitieux.

5.2 Première application au pancréas

Le passage à *MSD Pancreas* introduit deux difficultés. D'abord, la classe `tumor` n'appartient pas au vocabulaire pertinent du *checkpoint* pré-entraîné `swin-T objects365+goldg` ; appliqué en *zero-shot*, le modèle produit des boîtes quasiment aléatoires (mAP $< 0{,}05$). Nous adaptons donc *Grounding DINO* à deux classes (`pancreas`, `tumor`) en dégelant les quatre *stages* du backbone, en abaissant le taux d'apprentissage à 10^{-5}, en activant trois chaînes *distractor* échantillonnées, et en utilisant le *prompt* composé "`pancreas . tumor .`". L'entraînement converge en 25 époques sur GPU T4 et le meilleur *checkpoint* atteint un mAP_{COCO} d'environ 0,30 sur la validation, ce qui constitue notre meilleur détecteur.

Une fois le détecteur spécialisé, nous reprenons la chaîne canonique en conservant la boîte tumeur de plus haut score et en l'envoyant à *MedSAM*. Le tableau 1 reporte les métriques sur le *split* test. La sensibilité est quasi-parfaite (0,98), mais la spécificité tombe à 0,17 parce que *DINO* produit systématiquement une boîte même sur les coupes sans tumeur. Comme *MedSAM* segmente toujours quelque chose dans cette boîte, la spécificité reflète directement le comportement du détecteur. Le DICE moyen sur les images positives reste modéré (0,47), une partie des boîtes étant centrée sur du parenchyme sain plutôt que sur la tumeur.

Méthode	Sens.	Spéc.	DICE	F1
Oracle MedSAM (boîte GT)	1,00	–	0,88	–
DINO+MedSAM *one-shot*	0,98	0,17	0,47	0,78
+ agent Gemini	0,96	0,21	0,46	0,77
+ U-Net pancréas (strict)	0,73	0,50	0,34	0,71
+ U-Net pancréas (relâché)	0,92	0,30	0,45	0,77
Cascade panc.→tum. (V2)	0,94	0,40	0,50	0,80
Recall ResNet ens.	**0,88**	**0,74**	**0,54**	**0,81**

Table 1: Performances comparatives sur le *split* test MSD (100 images, 50 positives / 50 négatives). DICE calculé sur les images positives uniquement.

Cette observation oriente la suite de notre travail. Le segmenteur n'est pas en cause, comme le montre la borne supérieure obtenue en oracle (DICE 0,88 lorsqu'on fournit à MedSAM la boîte *ground-truth* de la tumeur). Toute amélioration ultérieure doit donc s'attaquer à la génération de boîtes par *Grounding DINO* ou ajouter un mécanisme de rejet en aval.

5.3 Tentative de raffinement par agent multimodal

La première idée que nous explorons est de demander à un modèle multimodal externe de vérifier ou de corriger les boîtes douteuses. Le notebook `agentic_segmentation_msd.ipynb` branche *Gemini* 2.0 [Team, 2024] en aval de *DINO*. À chaque étape l'agent reçoit le *prompt* courant, la boîte top-1, le masque *MedSAM* et un *crop* de la région, et peut renvoyer une action parmi `shrink`, `expand`, `shift`, `accept` et `reject`.

Trois observations conduisent à abandonner cette piste. D'abord, l'agent accepte la majorité des hallucinations parce que rien ne distingue, dans le *crop* présenté, un faux positif d'un vrai. Ensuite, son comportement reste non déterministe même à température nulle, ce qui empêche toute calibration fiable. Enfin, le coût moyen d'environ 2 s par appel rend l'évaluation prohibitive sur 100 images. Le tableau 1 montre que ce mécanisme n'apporte qu'un gain marginal de spécificité (0,17 → 0,21). Nous concluons que la vérification doit provenir d'un modèle plus spécialisé que d'un LLM généraliste, et nous orientons l'effort vers des informations anatomiques explicites.

5.4 Porte anatomique fondée sur un U-Net du pancréas

Puisque les hallucinations de *DINO* sont distribuées sur l'ensemble de l'image, une manière naturelle de les filtrer consiste à contraindre les boîtes à tomber sur le pancréas. Nous entraînons un *U-Net* sur le label `1` du MSD, conformément à la section 3.2, puis nous rejetons toute boîte dont l'*overlap* avec le masque pancréas dilaté est inférieur à un seuil τ_{ov}. Un seuil τ sur le score *DINO* complète ce filtrage spatial.

Une première version stricte ($\tau_{\text{ov}} = 0{,}10$, dilatation 15 px, masque clipé au ROI) améliore la spécificité à 0,50 mais sacrifie 25 points de sensibilité parce que le pancréas prédit ne couvre pas toujours la tumeur. Une seconde version relâchée ($\tau_{\text{ov}} = 0{,}05$, dilatation 35 px, perte de Tversky pour le U-Net) restaure 0,92 de sensibilité mais ne gagne que peu en spécificité (0,30) parce que le ROI élargi laisse passer les hallucinations intra-pancréatiques. La porte anatomique apparaît donc utile mais incomplète : elle ne sait pas distinguer une vraie tumeur d'une fausse alarme située sur l'organe.

5.5 Cascade pancréas→tumeur exploitant le détecteur

L'observation précédente suggère d'éviter le coût d'un modèle supplémentaire en exploitant directement la double sortie de notre *DINO* v3. Comme la configuration entraîne simultanément les classes `pancreas` et `tumor`, nous gardons la boîte `pancreas` de plus haut score, la dilatons de 20 px, et n'acceptons une boîte `tumor` que si elle recouvre ce voisinage à au moins 10 %. Un *post-processing* élémentaire (composante connexe maximale, filtre de taille) supprime les masques aberrants. Cette logique est documentée dans `experiments/baseline_v2/`.

Le gain est significatif (spécificité 0,40 et DICE 0,50) sans entraîner de modèle supplémentaire, ce qui simplifie la chaîne. La spécificité plafonne cependant en deçà de 0,50, signe qu'une part des hallucinations partage la même localisation que les vraies tumeurs et ne peut donc pas être rejetée par un simple critère spatial.

5.6 Classifieur ResNet-18 d'ensemble

Les sections précédentes montrent que les filtres spatiaux et sémantiques déplacent le compromis sensibilité/spécificité sur la même courbe sans en changer la forme globale. Pour modifier qualitativement ce compromis, il faut introduire un nouveau signal d'apprentissage. Nous entraînons donc un classifieur *patch-level* qui juge chaque candidat à partir de sa texture locale, signal qui n'est présent ni dans *DINO* ni dans le *U-Net* pancréas.

Le pipeline final, documenté dans `MSD_RECALL_STRATEGY.md`, opère ainsi. *DINO* génère jusqu'à cinq candidats à un seuil abaissé de 0,05, plus permissif que précédemment afin de ne pas sacrifier la sensibilité en amont. Le filtre pancréas reste actif mais relativement large (marge 35 px). Chaque candidat survivant est cropé en 224×224 puis passé à cinq ResNet-18 entraînés sur le même jeu de *patches* mais avec des graines différentes. Les probabilités sont agrégées par moyenne pénalisée (équation 2). Au moment de la décision, on conserve les candidats dont le score d'ensemble dépasse un seuil τ_{ResNet} calibré sur la validation par balayage $F_{\beta=2}$ avec contrainte de précision $P \geq 0{,}80$. Jusqu'à deux candidats sont alors envoyés à *MedSAM* et leurs masques sont fusionnés par union.

La qualité de cette décision repose entièrement sur le jeu d'entraînement du classifieur. Si l'on se contentait de positifs et de négatifs choisis au hasard, le ResNet apprendrait des indices triviaux comme la présence de muqueuse intestinale ou la teinte générale, et n'attaquerait pas le problème réel des hallucinations de *DINO*. Nous échantillonnons donc les négatifs durs en abaissant le seuil de *DINO* à 0,01 et *top-k* = 12 pendant l'extraction (`extract_hard_negatives.py`), suivant l'esprit d'*Online Hard Example Mining* [Shrivastava *et al.*, 2016]. Les positifs *ground-truth* sont légèrement *jitterés*

Fold ResNet	Seuil $\tau_{\beta=2}$
1	0,539
2	0,343
3	0,564
4	0,841
5	0,641
Médiane	0,564
Seuil ensemble retenu	0,370

Table 2: Seuils ResNet par *fold* sur la validation. La large dispersion motive l'agrégation par moyenne pénalisée.

(translation $\pm 12\,\%$, *scale* $\pm 18\,\%$) pour robustifier le modèle, et le ratio final est borné entre 2:1 et 4:1 négatifs/positifs.

Le tableau 1 reporte le gain. La spécificité atteint 0,74 contre 0,17 pour le *baseline*, soit une amélioration de 57 points, au prix d'une perte de 10 points de sensibilité. Le F1 monte à 0,81 et le DICE moyen sur images positives à 0,54.

5.7 Calibration du seuil et analyse des faux négatifs

Les seuils *per-fold* obtenus pendant l'entraînement (tableau 2) montrent une variabilité marquée, signe que les cinq réseaux apprennent des décisions sensiblement différentes. Cette variabilité justifie *a posteriori* le choix d'un ensemble plutôt que d'un modèle unique. Le seuil global retenu pour le test (0,37) provient de l'agrégation par moyenne pénalisée, qui déplace légèrement la décision vers la prudence.

Le script `test_gd_msd_final_recall.py` étiquette chaque faux négatif selon sa cause directe. La majorité tombe dans la catégorie `dino_or_spatial_filters`, c'est-à-dire que *DINO* ne propose aucun candidat sur la coupe concernée. Le classifieur n'est donc pas limitant en sensibilité, et la borne supérieure que pourrait atteindre notre chaîne dépend principalement du *recall* du détecteur amont.

6 Analyse Critique

Le *fine-tuning* de *Grounding DINO* avec *focal loss* et trois chaînes *distractor* se révèle indispensable ; sans cet ajustement, le modèle transféré en *zero-shot* ne dépasse pas mAP$<$0,05 et la chaîne complète devient inutilisable. La chaîne *detector+MedSAM* reste un *baseline* solide en sensibilité dès lors que le détecteur est spécialisé, parce que *MedSAM* tolère une boîte même grossière et atteint 0,88 de DICE en oracle.

L'utilisation de *prompts* négatifs tels que "`no tumor`" échoue parce que l'encodeur BERT [Devlin *et al.*, 2019] ne traite pas la négation sémantiquement. L'introduction de *distractors* positifs ("`normal pancreas tissue`", "`bowel gas`") a un effet plus tangible mais limité à une dizaine de points de précision.

L'échec de la boucle agentique mérite quelques mots. Nous espérions qu'un modèle multimodal *frontier* pourrait jouer le rôle d'un second avis radiologique, mais trois facteurs combinent leurs effets contre cette espérance. Le *crop* présenté a une résolution insuffisante pour discriminer une tumeur d'un parenchyme sain, le modèle tend à accepter par défaut, et son non-déterminisme rend toute calibration peu fiable.

L'analyse comparative du tableau 1 dégage un schéma clair. Les portes purement spatiales ou par seuil déplacent le point de fonctionnement le long d'une même courbe sensibilité/spécificité sans changer sa forme. Seul le ResNet d'ensemble parvient à décaler la courbe globalement, parce qu'il apporte un signal d'apprentissage supplémentaire que ne capture aucun autre composant. Sa décomposition en *region proposal* amont et classification *patch-level* aval rappelle *Mask R-CNN* [He *et al.*, 2017], et confirme empiriquement que la texture locale d'un *patch* est un critère complémentaire à un score d'alignement texte-image.

Notre protocole d'évaluation présente néanmoins deux limites méthodologiques importantes. D'une part, toutes les métriques sont calculées sur des coupes 2D indépendantes, alors que les tumeurs pancréatiques apparaissent typiquement sur plusieurs coupes adjacentes, contrairement aux hallucinations. Une simple agrégation *multi-slice* améliorerait probablement la spécificité sans coût sensibilité. D'autre part, le *split* 50/50 du test a été construit pour faciliter la comparaison entre méthodes, mais ne reflète pas la prévalence clinique réelle des coupes pathologiques. Une évaluation sur une distribution naturelle réévaluerait la valeur pratique de chaque composant.

Enfin, l'ensemble des *checkpoints* (DINO v3, U-Net pancréas, cinq ResNet-18) tient en moins d'un gigaoctet, et l'inférence *end-to-end* sur une coupe prend environ 300 ms sur GPU T4. Le coût total d'entraînement reste sous 90 minutes de calcul GPU, soit un ordre de grandeur inférieur à celui de *nnU-Net* 3D pour un problème comparable, ce qui rend notre approche intéressante pour des déploiements rapides.

7 Conclusion

Notre projet documente une transition. Sur *Kvasir-SEG*, la chaîne *Grounding DINO+MedSAM* fonctionne pratiquement sans intervention humaine et atteint un DICE oracle de 0,95. Sur *MSD Pancreas*, la même chaîne s'effondre en spécificité, et seule l'introduction d'un classifieur appris en aval restaure un compromis exploitable. Nos expériences montrent que les filtres spatiaux et les agents multimodaux ne déplacent que la position le long d'une courbe fixe, tandis qu'un signal d'apprentissage *patch-level*, entraîné sur les négatifs durs générés par le détecteur lui-même, change qualitativement le compromis. Le pipeline final atteint un F1 de 0,81 et un DICE moyen de 0,54 sur les coupes positives. L'intégralité du code, des données et des *checkpoints* est publiée à https://github.com/moradBMH/INF8225_Projet.

Remerciements

Nous remercions les chargés de laboratoire INF8225 pour leurs retours méthodologiques, ainsi que les auteurs de *MedSAM*, *Grounding DINO* et de la base *Medical Segmentation Decathlon* pour la mise à disposition de leurs artefacts.

References

[Antonelli *et al.*, 2022] Michela Antonelli, Annika Reinke, Spyridon Bakas, et al. The Medical Segmentation Decathlon. *Nature Communications*, 13(4128), 2022.

[Caron *et al.*, 2021] Mathilde Caron, Hugo Touvron, Ishan Misra, et al. Emerging properties in self-supervised vision transformers. *International Conference on Computer Vision (ICCV)*, 2021.

[Devlin *et al.*, 2019] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. *Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*, 2019.

[He *et al.*, 2016] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[He *et al.*, 2017] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask R-CNN. In *International Conference on Computer Vision (ICCV)*, 2017.

[Isensee *et al.*, 2021] Fabian Isensee, Paul F. Jaeger, Simon A. A. Kohl, Jens Petersen, and Klaus H. Maier-Hein. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, 18(2):203–211, 2021.

[Kirillov *et al.*, 2023] Alexander Kirillov, Eric Mintun, Nikhila Ravi, et al. Segment anything. *International Conference on Computer Vision (ICCV)*, 2023.

[Lin *et al.*, 2017] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. *International Conference on Computer Vision (ICCV)*, pages 2980–2988, 2017.

[Liu *et al.*, 2024] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, et al. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. *European Conference on Computer Vision (ECCV)*, 2024.

[Ma *et al.*, 2024] Jun Ma, Yuting He, Feifei Li, Lin Han, Chenyu You, and Bo Wang. Segment anything in medical images. *Nature Communications*, 15(654), 2024.

[Ronneberger *et al.*, 2015] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional networks for biomedical image segmentation. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241, 2015.

[Salehi *et al.*, 2017] Seyed Sadegh Mohseni Salehi, Deniz Erdogmus, and Ali Gholipour. Tversky loss function for image segmentation using 3D fully convolutional deep networks. *Machine Learning in Medical Imaging (MLMI)*, pages 379–387, 2017.

[Shrivastava *et al.*, 2016] Abhinav Shrivastava, Abhinav Gupta, and Ross Girshick. Training region-based object detectors with online hard example mining. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 761–769, 2016.

[Team, 2024] Gemini Team. Gemini: A family of highly capable multimodal models. *arXiv preprint arXiv:2312.11805*, 2024.

[Wei *et al.*, 2022] Jason Wei, Xuezhi Wang, Dale Schuurmans, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

[Zhou *et al.*, 2017] Yuyin Zhou, Lingxi Xie, Wei Shen, Yan Wang, Elliot K. Fishman, and Alan L. Yuille. A fixed-point model for pancreas segmentation in abdominal CT scans. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 693–701, 2017.

[Zhu *et al.*, 2019] Zhuotun Zhu, Yongyi Lu, Wei Shen, Elliot K. Fishman, and Alan L. Yuille. Multi-scale coarse-to-fine segmentation for screening pancreatic ductal adenocarcinoma. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 3–12, 2019.