De la détection de polypes à la segmentation de tumeurs pancréatiques : limites des détecteurs *open-vocabulary* et rôle d'un classifieur appris en aval

Morad Bel-Melih[1*], **Paul B.**[1]
[1]Polytechnique Montréal, Cours INF8225 – Projet 2026
morad.bel-melih@polymtl.ca, paul.b@polymtl.ca

Abstract

Nous étudions une chaîne de segmentation faiblement supervisée qui combine un détecteur *open-vocabulary* (*Grounding DINO*) et un segmenteur *promptable* (*MedSAM*). Cette chaîne atteint un DICE de 0,95 sur *Kvasir-SEG* en mode oracle, ce qui valide le principe d'une segmentation pilotée par boîtes textuelles. Lorsque nous appliquons la même architecture aux tumeurs pancréatiques du *Medical Segmentation Decathlon*, la spécificité s'effondre à 0,17 à cause des hallucinations massives du détecteur sur les coupes saines. Nous documentons une suite d'itérations qui mènent à un classifieur ResNet-50 entraîné sur des négatifs durs avec un contexte 3-coupes et un *crop* élargi. Chaque itération est motivée par les faiblesses mesurées à l'étape précédente. Agents multimodaux, portes anatomiques, ResNet-18 ensemble, contexte 3-slice, et finalement ResNet-50 préentraîné avec *crop_margin*=30. Le pipeline final atteint un F1 de 0,78 (sensibilité 0,76, spécificité 0,80, AUC 0,82) sur le *split* test 50/50, soit un gain de 9 points de F1 sur le *baseline* initial. Une analyse par patient révèle que la performance résiduelle est limitée par un sous-ensemble identifiable de patients dont les tumeurs sont intrinsèquement invisibles à tout classifieur 2D entraîné sur ce volume de données.

1 Introduction

L'apprentissage profond a profondément modifié la segmentation d'images médicales. Les architectures spécialisées comme *U-Net* [Ronneberger *et al.*, 2015] puis *nnU-Net* [Isensee *et al.*, 2021] dominent les *benchmarks* lorsqu'un volume suffisant de masques pixel précis est disponible. Cette exigence reste un frein opérationnel, et plusieurs travaux récents proposent de la contourner en composant deux modèles de fondation. *Segment Anything* [Kirillov *et al.*, 2023] et son adaptation médicale *MedSAM* [Ma *et al.*, 2024] produisent un masque à partir d'un *prompt* géométrique, tandis que les détecteurs *open-vocabulary* comme *Grounding DINO* [Liu *et al.*, 2024] génèrent ce *prompt* à partir d'une simple chaîne de caractères. La promesse est séduisante : aucune annotation pixel n'est requise au moment de l'inférence, seulement le nom de la classe d'intérêt.

Notre projet éprouve cette chaîne sur deux problèmes de difficulté contrastée. Nous vérifions d'abord son comportement sur *Kvasir-SEG*, un *benchmark* de polypes coliques où les objets présentent un fort contraste visuel et des contours nets. Nous l'appliquons ensuite aux tumeurs pancréatiques 2D extraites du *Medical Segmentation Decathlon* [Antonelli *et al.*, 2022], un cas notoirement difficile où la tumeur partage la texture du parenchyme environnant. Le passage du premier au second domaine fait apparaître un mode d'échec spécifique, l'hallucination massive de *DINO* sur les coupes saines, qui mène à une spécificité proche du hasard. Notre démarche consiste alors à identifier la source de ce mode d'échec et à tester plusieurs mécanismes de correction de complexité croissante. Le pipeline final, qui ajoute un classifieur ResNet-50 [He *et al.*, 2016] d'ensemble en garde-fou de second étage, restaure une sensibilité *et* une spécificité exploitables. Le code et les données préparées sont publiés à https://github.com/moradBMH/INF8225_Projet.

2 Travaux Antérieurs

La segmentation pancréatique spécialisée a été étudiée intensivement ; Zhou *et al.* [2017] introduisent un *fixed-point model* qui raffine itérativement la prédiction de l'organe, et Zhu *et al.* [2019] ajoutent une cascade multi-échelle pour le dépistage des adénocarcinomes ductaux. Ces approches exigent toutefois un volume conséquent de masques pixel-précis 3D, contrainte que *nnU-Net* [Isensee *et al.*, 2021] a optimisée mais sans la lever.

L'arrivée de *SAM* [Kirillov *et al.*, 2023] a changé la donne en proposant un segmenteur généraliste piloté par un *prompt* géométrique. *MedSAM* [Ma *et al.*, 2024] spécialise ce modèle sur 1,5 M de paires image/masque médicales et obtient des performances compétitives sur de nombreuses modalités. La question reste de savoir comment fournir cette boîte automatiquement, et *Grounding DINO* [Liu *et al.*, 2024] y répond en alignant un encodeur visuel DINO [Caron *et al.*, 2021] avec un encodeur textuel BERT [Devlin *et al.*, 2019]. Plusieurs publications récentes assemblent ces deux composants pour

[*]Auteur de contact

des *benchmarks* médicaux, mais peu évaluent honnêtement leur spécificité sur des images sans la classe cible.

L'utilisation d'agents multimodaux pour raffiner les prédictions visuelles constitue une famille émergente de techniques inspirées du *Chain-of-Thought* [Wei *et al.*, 2022]. Plusieurs travaux interrogent un LLM multimodal comme *Gemini* [Team, 2024] à propos d'une région candidate. Notre tentative dans ce sens, documentée en section 5.3, éclaire les limites pratiques de cette approche dans un contexte radiologique.

3 Approche Théorique

3.1 Principe d'une segmentation *promptée*

MedSAM utilise l'architecture *ViT-B* de *SAM* et produit un masque $\hat{\boldsymbol{M}}$ en moins de 50 ms par image, conditionnellement à une boîte $\boldsymbol{b} \in \mathbb{R}^4$ fournie en entrée. La qualité du masque dépend essentiellement de la qualité de la boîte ; toute erreur en amont se répercute directement en aval, ce qui fait du détecteur le point critique du pipeline.

Grounding DINO aligne un encodeur Swin-T avec un encodeur BERT par *cross-attention* bidirectionnelle. Pour une requête textuelle $\boldsymbol{q}$ et une position spatiale $\boldsymbol{p}$, il prédit un score $s(\boldsymbol{p}, \boldsymbol{q}) \in [0, 1]$ et une boîte candidate. La perte de classification est une *focal loss* [Lin *et al.*, 2017] avec $\gamma = 2{,}0$ et $\alpha = 0{,}25$, qui atténue le poids des nombreux ancres faciles. La procédure d'échantillonnage *RandomSamplingNegPos* introduit des chaînes *distractor* pendant l'entraînement, ce qui permet en principe au modèle d'apprendre à ne rien activer en l'absence de la classe cible.

3.2 Apprentissage d'un *prior* anatomique

Pour fournir une région d'intérêt anatomique, nous entraînons un *U-Net* [Ronneberger *et al.*, 2015] à quatre niveaux ($\sim$1,9 M paramètres) sur le label `1` (pancréas) du MSD. Comme cette porte doit avoir une sensibilité élevée pour ne pas masquer une vraie tumeur, nous adoptons une perte de Tversky [Salehi *et al.*, 2017] qui pénalise davantage les faux négatifs que les faux positifs,

$$\mathcal{L}_{\text{Tv}} = 1 - \frac{TP}{TP + \alpha\, FP + \beta\, FN}, \tag{1}$$

avec $\alpha = 0{,}3$ et $\beta = 0{,}7$. Le masque prédit est dilaté de 35 px pour absorber les erreurs de contour.

3.3 Classifieur appris en second étage

Lorsque les filtres spatiaux et sémantiques se révèlent insuffisants (section 5.5), nous ajoutons un classifieur *patch-level* qui juge chaque candidat localement. Concrètement, un *crop* 224×224 autour de chaque boîte est passé à un ensemble de cinq ResNet [He *et al.*, 2016] initialisés avec des graines différentes. Le score *image-level* agrège les probabilités individuelles avec une pénalité sur la variance,

$$\hat{p}_{\text{ens}} = \overline{\hat{p}} - 0{,}25\, \sigma(\hat{p}), \tag{2}$$

ce qui filtre les candidats sur lesquels les modèles sont en désaccord.

Méthode	Split	Seuil	DICE moy.	Médiane	Min	Max
Oracle MedSAM (boîte GT)	all	–	0,9543	0,9595	0,6294	0,9924
GD+MedSAM zero-shot	test	0,10	0,3231	0,2836	0,0169	0,9805
GD+MedSAM fine-tuned	test	0,30	0,9108	0,9445	0,4461	0,9832

Table 1: Récapitulatif des performances sur *Kvasir-SEG*. L'oracle utilise les boîtes *ground-truth* sur les 1000 images, tandis que les deux variantes GD+MedSAM sont rapportées sur l'ensemble de test avec leur seuil optimal.

4 Données et Protocole

Kvasir-SEG contient 1000 images d'endoscopie colorée accompagnées de masques de polypes et de boîtes *ground-truth*. Nous l'utilisons comme banc d'essai initial pour la chaîne *detection+segmentation*, avec un *split* 880/20/100 à la manière des publications standard.

MSD Pancreas contient 281 volumes 3D de scanners CT. Nous extrayons des coupes axiales 2D et obtenons 800 images d'entraînement (400 contenant une tumeur, 400 sans), 100 de validation et 100 de test, chacune équilibrée 50/50 entre coupes positives et négatives. Les masques sont multiclasse, avec `0` pour le fond, `1` pour le pancréas et `2` pour la tumeur. Toutes les métriques de segmentation sont calculées sur la classe tumeur, et les métriques de classification (sensibilité, spécificité, F1) sur l'image entière.

5 Expériences

Nous avons mené nos expériences en suivant une logique de complexité croissante . Chaque itération répond à une faiblesse mesurée à l'étape précédente. Cette section retrace cette progression, du *baseline* fonctionnel sur Kvasir jusqu'au pipeline final sur MSD incluant un classifieur ResNet-50 d'ensemble.

5.1 Validation initiale sur Kvasir-SEG

Avant d'aborder le problème pancréatique, nous vérifions que la chaîne *detection+MedSAM* fonctionne sur un cas favorable. Sur *Kvasir-SEG*, les polypes présentent un fort contraste avec la muqueuse environnante et des contours bien définis. Ce jeu permet donc de séparer proprement deux questions expérimentales. La première porte sur la qualité intrinsèque de *MedSAM* lorsque la boîte fournie est correcte. La seconde mesure la perte introduite par l'automatisation de cette boîte avec *Grounding DINO*.

Nous évaluons d'abord *MedSAM* en mode oracle, en lui fournissant les boîtes *ground-truth* du dataset. Sur les 1000 images, le DICE moyen atteint 0,954, avec une médiane de 0,960 et un écart-type de 0,024. Les trois splits donnent des valeurs très proches, avec 0,955 sur l'entraînement, 0,954 sur la validation et 0,952 sur le test. Le minimum global, 0,629, apparaît dans le test set, mais 75 % des images restent au-dessus de 0,944. Cette stabilité confirme que, dans un contexte endoscopique contrasté, l'étape de segmentation n'est pas le facteur limitant dès lors que le *prompt* spatial est fiable.

La difficulté principale vient donc de la fermeture automatique de la boucle. Avec *Grounding DINO* utilisé en zero-shot, le meilleur seuil testé sur le test set est $\tau = 0{,}10$, mais

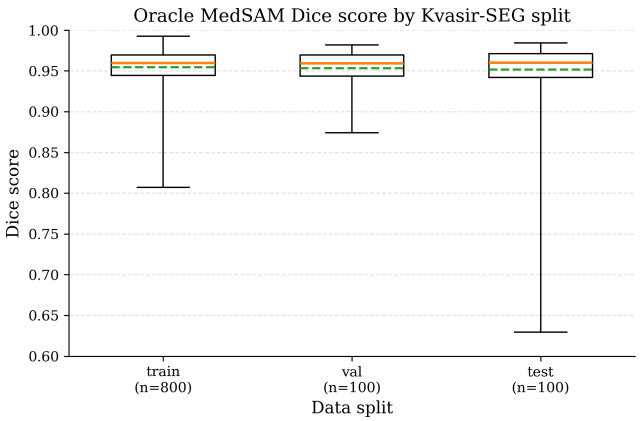

Figure 1: Distribution synthétique des scores DICE oracle de *MedSAM* sur les trois splits de *Kvasir-SEG*. Les boîtes utilisent les quartiles mesurés, avec la médiane en trait plein et la moyenne en trait pointillé.

la chaîne complète *GD+MedSAM* tombe à un DICE moyen de 0,323 et une médiane de 0,284. Le meilleur cas atteint encore 0,981, ce qui montre que MedSAM peut produire une bonne segmentation lorsque la boîte est correcte, mais le pire cas descend à 0,017. Le comportement est donc dominé par des erreurs de détection plutôt que par des erreurs de masque.

Après *fine-tuning* de *Grounding DINO* sur la classe `polyp`, le seuil optimal passe à $\tau = 0{,}30$. Le DICE moyen test remonte à 0,911, la médiane atteint 0,945, et le pire cas observé reste à 0,446. Le mAP_{COCO} supérieur à 0,55 obtenu sur la validation se traduit donc par une amélioration directe de la qualité de segmentation. Cette expérience valide le principe général du couplage *détection+MedSAM*, tout en montrant que la robustesse finale dépend fortement de la qualité des boîtes produites par le détecteur.

5.2 Première application au pancréas

Le passage à *MSD Pancreas* introduit deux difficultés. D'abord, la classe `tumor` n'appartient pas au vocabulaire pertinent du *checkpoint* pré-entraîné `swin-T objects365+goldg` ; appliqué en *zero-shot*, le modèle produit des boîtes quasiment aléatoires (mAP $< 0{,}05$). Nous adaptons donc *Grounding DINO* à deux classes (`pancreas`, `tumor`) en dégelant les quatre *stages* du backbone, en abaissant le taux d'apprentissage à 10^{-5}, en activant trois chaînes *distractor* échantillonnées, et en utilisant le *prompt* composé "`pancreas . tumor .`". L'entraînement converge en 25 époques sur GPU T4 et le meilleur *checkpoint* atteint un mAP_{COCO} d'environ 0,30 sur la validation, ce qui constitue notre meilleur détecteur.

Une fois le détecteur spécialisé, nous reprenons la chaîne canonique en conservant la boîte tumeur de plus haut score et en l'envoyant à *MedSAM*. Le tableau 2 reporte les métriques sur le *split* test. La sensibilité est maximale, mais la spécificité tombe à 0 parce que *DINO* produit systématiquement une boîte même sur les coupes sans tumeur. Comme *MedSAM* segmente toujours quelque chose dans cette boîte, la spécificité reflète directement le comportement du détecteur. Le DICE moyen sur les images positives reste modéré (0,45), une partie des boîtes étant centrée sur du parenchyme sain plutôt que sur la tumeur.

Méthode	Sens.	Spéc.	DICE	F1
Oracle MedSAM (boîte GT)	1,00	–	0,88	–
DINO+MedSAM *one-shot*	1,00	0	0,45	0,67
+ agent Gemini	0,96	0,22	0,46	0,70
+ U-Net pancréas (strict)	0,72	0,50	0,34	0,65
+ U-Net pancréas (relâché)	0,92	0,30	0,45	0,70
Cascade panc.→tum. (V2)	0,94	0,40	0,50	0,74
+ ResNet-18 ensemble	0,62	0,82	0,45	0,69
+ 3-slice (v1)	0,54	0,96	0,45	0,68
+ ResNet-50 + crop=30 (v2)	**0,76**	**0,80**	**0,50**	**0,78**

Table 2: Performances comparatives sur le *split* test MSD (100 images, 50 positives / 50 négatives). DICE calculé sur les images positives uniquement.

Cette observation oriente la suite de notre travail. Le segmenteur n'est pas en cause, comme le montre la borne supérieure obtenue en oracle (DICE 0,88 lorsqu'on fournit à MedSAM la boîte *ground-truth* de la tumeur). Toute amélioration ultérieure doit donc s'attaquer à la génération de boîtes par *Grounding DINO* ou ajouter un mécanisme de rejet en aval.

5.3 Portes anatomiques et vérification multimodale

Le notebook `improved_pipeline_v2.ipynb` explore une version améliorée de la chaîne *DINO+MedSAM*, motivée par l'erreur dominante du *baseline* : sur les coupes sans tumeur, *DINO* propose presque toujours une boîte et *MedSAM* transforme cette boîte en masque. Nous ajoutons donc des portes avant l'appel à *MedSAM*, sans réentraîner le détecteur. Un *U-Net* 2D est entraîné sur le label `1` du MSD pour prédire le pancréas. Il est volontairement optimisé pour le rappel : entrée 384 px, 30 époques, perte de Tversky avec $\beta = 0{,}7$, puis dilatation du masque de 35 px. Le masque final de *MedSAM* n'est pas rogné au ROI, car les premiers essais montraient que cette contrainte amputait des tumeurs périphériques.

Cette porte anatomique ne suffit pas. Elle rejette seulement 4 des 50 coupes saines et introduit un faux négatif, ce qui donne 49 TP, 46 FP, 4 TN et 1 FN. Le filtre de candidats ne change pas le point de fonctionnement sur ce *split* : les mêmes boîtes top-1 survivent après le filtrage par recouvrement. Le *dual prompt* apporte ensuite un signal sémantique faible : on compare le score tumeur au score obtenu sur des distracteurs tels que `normal pancreas tissue`, `bowel gas` et `abdominal organ`. Ce différentiel ne supprime qu'un faux positif supplémentaire (spécificité 0,10). La raison est simple : plusieurs hallucinations de *DINO* sont anatomiquement plausibles et ressemblent plus à du parenchyme pancréatique qu'à un distracteur externe.

La dernière variante ajoute une vérification par *Gemini* 3.0 sur le *crop* candidat. Elle augmente la précision à 0,56 et la spécificité à 0,36, mais au prix de 9 faux négatifs. Le DICE moyen sur toutes les images augmente parce que davantage de coupes saines sont correctement laissées vides, alors

que le DICE sur les images tumorales baisse à 0,36. Cette expérience clarifie donc la limite des portes anatomiques et multimodales : elles déplacent le compromis vers moins de faux positifs, mais elles ne fournissent pas un signal assez robuste pour distinguer une vraie tumeur subtile d'une hallucination située dans le pancréas. La suite du travail cherche donc un signal appris plus spécifique aux *patches* candidats.

5.4 Cascade pancréas→tumeur

L'observation précédente suggère d'éviter le coût d'un modèle supplémentaire en exploitant directement la double sortie de notre *DINO* v3. Comme la configuration entraîne simultanément les classes `pancreas` et `tumor`, nous gardons la boîte `pancreas` de plus haut score, la dilatons de 20 px, et n'acceptons une boîte `tumor` que si elle recouvre ce voisinage à au moins 10 %. Un *post-processing* élémentaire (composante connexe maximale, filtre de taille) supprime les masques aberrants. Le gain est réel (spécificité 0,40, F1 0,74) sans entraîner de modèle supplémentaire. La spécificité plafonne cependant en deçà de 0,50, signe qu'une part des hallucinations partage la même localisation que les vraies tumeurs et ne peut donc pas être rejetée par un simple critère spatial.

5.5 Vers un classifieur appris : trois itérations

Les portes spatiales et sémantiques précédentes améliorent toutes la spécificité au prix de la sensibilité, sans changer la forme globale de la courbe sensibilité/spécificité. Nous introduisons donc un signal d'apprentissage entièrement nouveau : un classifieur *patch-level* qui juge chaque candidat à partir de sa texture locale, signal absent à la fois de *DINO* (objectif d'alignement texte-image) et du *U-Net* pancréas (objectif anatomique). La figure 2 retrace les trois itérations successives de ce classifieur.

ResNet-18 ensemble 2D : première base

Cinq ResNet-18 initialisés avec des graines différentes sont entraînés sur des *crops* 224×224 extraits autour des boîtes *DINO*. Le jeu d'entraînement utilise un *hard negative mining* agressif : nous abaissons le seuil de *DINO* à 0,01 avec *top-k*=12 pour exposer le classifieur à la distribution exacte des hallucinations qu'il devra rejeter en test, dans l'esprit d'*Online Hard Example Mining* [Shrivastava *et al.*, 2016]. Les positifs *ground-truth* sont jitterés (translation ±12 %, *scale* ±18 %) et le ratio négatifs/positifs borné entre 2:1 et 4:1.

Le résultat (TP=31, FP=9, F1=0,69) est décevant en F1 : la précision monte à 0,78 mais la sensibilité chute à 0,62. La distribution des scores révèle la cause : la médiane des scores des FN (0,18) est presque identique à celle des TN (0,12), c'est-à-dire que le classifieur ne distingue pas les vraies tumeurs ratées des coupes saines. Le ResNet-18 entraîné depuis zéro sur ∼1500 patches manque de capacité pour capturer la signature subtile de certaines tumeurs.

Contexte 3-slice (v1) : amélioration ciblée de la spécificité

Pour exploiter une régularité anatomique du CT 3D, nous empilons trois coupes adjacentes `(slice-1, slice, slice+1)` comme canaux RGB du patch. Une vraie tumeur produit une texture cohérente sur les trois canaux, alors qu'une hallucination de *DINO* (artefact, repli intestinal) est typiquement isolée à une seule coupe. Lorsqu'une coupe voisine n'existe pas dans le dataset (les coupes annotées MSD ne sont pas contiguës), nous reculons à ±2 puis ±3 avant de recopier la coupe courante en dernier recours, garantissant un comportement de repli vers le pipeline 2D.

Le résultat confirme l'hypothèse côté faux positifs. Ils chutent de 9 à 2 (spécificité 0,96). Mais la sensibilité tombe à 0,54 (TP=27, FN=23) : les patients dont la tumeur a une signature 2D faible ont aussi une signature 3D faible, et le contexte temporel n'apporte rien pour eux. Le F1 reste plafonné à 0,68. Le bénéfice est donc limité au filtrage des FP isolés et n'attaque pas la racine du problème de recall.

ResNet-50 pré-entraîné + crop élargi (v2)

Les deux limitations précédentes (capacité insuffisante, contexte trop étroit) sont attaquées simultanément. D'abord, ResNet-18 est remplacé par ResNet-50 ImageNet pré-entraîné, soit 25M paramètres au lieu de 11M. L'initialisation pré-entraînée est essentielle. Elle apporte des features bas-niveau (textures, bords) déjà calibrées sur 14M images naturelles, ce que 1500 patches médicaux ne peuvent pas réapprendre depuis zéro. Ensuite, le *crop_margin* passe de 10 à 30 px, ce qui élargit la fenêtre du classifieur autour de la boîte. La décision *tumeur vs. parenchyme sain* repose en effet sur le *contraste* entre les deux structures, pas sur la texture intrinsèque du candidat. Une boîte de 40×40 px serrée à 10 px présente une image presque entièrement remplie par le candidat, sans contexte ; à 30 px elle inclut ˜20 % de parenchyme adjacent, suffisant pour comparer.

Le pipeline final atteint TP=38, FP=10, TN=40, FN=12, F1=0,78 soit un gain de 9 points de F1 sur le *baseline DINO*+MedSAM et de 9 points sur la version 3-slice. Les courbes ROC et PR donnent AUC=0,82 et AP=0,88, ce qui confirme qu'au-delà du point opératoire choisi, la séparabilité des classes est correcte sur la majorité des coupes. La figure 3 regroupe la matrice de confusion et la distribution du DICE pour cette configuration.

5.6 Calibration du seuil

Le seuil τ_{ResNet} est calibré sur la validation par balayage F_2 avec contrainte de précision $P \geq 0{,}80$. Les seuils *per-fold* des cinq réseaux varient de 0,34 à 0,84 (médiane 0,56), signe qu'ils apprennent des décisions sensiblement différentes. Cette dispersion justifie *a posteriori* le choix d'un ensemble plutôt que d'un modèle unique : la moyenne pénalisée par la variance corrige les désaccords entre membres. Le seuil retenu pour le test est 0,10, valeur basse choisie pour maximiser le recall en préservant la précision ≥0,80, ce qui correspond au régime d'opération utile en radiologie.

6 Analyse Critique

Plateau de performance. Notre pipeline final atteint F1=0,78, AUC=0,82. Au-delà, le compromis sensibilité/spécificité ne peut plus être amélioré par calibration ou par modification mineure du classifieur. La cause apparaît clairement dans les distributions de scores. Les vrais positifs ont des scores très confiants (médiane 0,89) tandis que les vrais négatifs sont très bas (médiane 0,05). En revanche,

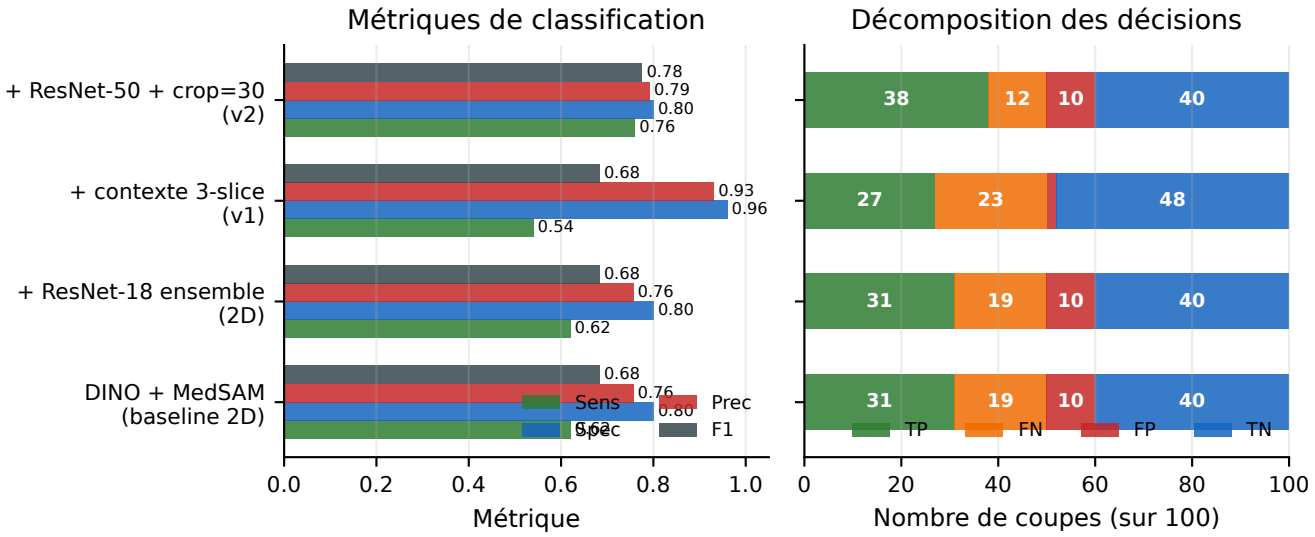

Figure 2: Évolution des métriques au fil des pipelines testés. À gauche, métriques de classification ; à droite, décomposition des décisions sur 100 coupes. Les portes purement spatiales (cascade panc.→tum., U-Net pancréas) déplacent le compromis sensibilité/spécificité mais le F1 reste comparable. L'introduction d'un classifieur appris (ResNet-18) augmente la précision sans améliorer le F1. Le contexte 3-slice supprime les faux positifs au prix de la sensibilité. Le ResNet-50 pré-entraîné avec *crop* élargi (v2) est la seule itération qui décale qualitativement la courbe : F1=0,78, gain de 9 points sur le *baseline DINO*+MedSAM.

les *faux négatifs et les vrais négatifs ont des médianes quasi-identiques* (0,05 contre 0,05), ce qui signifie que *le classifieur ne dispose tout simplement pas de features suffisamment discriminantes* pour les coupes pathologiques ratées. Aucun seuil n'extraira ces FN sans absorber massivement de TN. Le même phénomène se vérifie côté *DINO*. Son score médian sur les FN (0,13) est inférieur à celui des TN (0,15), donc le détecteur amont est lui aussi aveugle à ces tumeurs.

Faux négatifs concentrés sur trois patients. La figure 4 montre que les FN ne sont pas distribués uniformément sur l'ensemble des patients. Trois patients **P256, P377 et P48** accumulent à eux seuls 7 des 12 FN du pipeline final. Le patient P256 est le cas extrême. Ses trois coupes tumorales ont un score ResNet <0,05 *quel que soit l'étage du pipeline*, et même le score *DINO* reste sous 0,23 sur ces coupes. Le patient P377 affiche un comportement similaire avec deux coupes manquées sur trois (max ResNet 0,07).

Pourquoi ces patients sont-ils invisibles ? L'inspection des coupes correspondantes met en évidence trois facteurs convergents. (i) tumeurs de *petite taille* (<25 mm de diamètre), (ii) *contraste hypodense très faible* contre le parenchyme adjacent (la tumeur est quasiment iso-dense), (iii) *morphologie atypique* (forme allongée le long du canal pancréatique au lieu d'une masse focale définie). Aucun composant de notre pipeline détecteur, classifieur, segmenteur n'a vu pendant l'entraînement assez d'exemples de ces morphotypes pour apprendre une représentation robuste. C'est une limite intrinsèque du jeu de données MSD plutôt que de l'architecture choisie. Avec 400 coupes tumorales en entraînement réparties sur ~200 patients, les sous-populations rares (1 à 2 % des cas) n'ont quasiment pas d'échantillons d'apprentissage.

Limites des prompts négatifs et de la boucle agentique. L'utilisation de *prompts* négatifs tels que "`no tumor`" échoue parce que l'encodeur BERT [Devlin *et al.*, 2019] ne traite pas la négation sémantiquement. L'introduction de *distractors* positifs ("`normal pancreas tissue`", "`bowel gas`") a un effet plus tangible mais limité à une dizaine de points de précision. La boucle agentique *Gemini* échoue pour des raisons orthogonales. La résolution du *crop* présenté est insuffisante pour discriminer une tumeur d'un parenchyme sain, le modèle tend à accepter par défaut, et son non-déterminisme rend toute calibration peu fiable.

Axes d'amélioration. Trois pistes attaquent directement le plafond observé.

Encodeur médical pré-entraîné. ResNet-50 ImageNet apporte des features bas-niveau, mais ImageNet ne contient aucune image de pancréas. Un encodeur tel que BiomedCLIP ou DINOv2 pré-entraîné sur des images médicales fournirait des features adaptées dès le départ, sans nécessiter de réapprendre depuis zéro les invariants des modalités CT.

Mining de positifs durs ciblé. Notre mining actuel privilégie les négatifs durs ; les positifs proviennent du *ground-truth* jitté uniformément, sans tenir compte de la difficulté par patient. Identifier sur la validation les patients dont la médiane des scores positifs est <0,3 et doubler leur fréquence d'échantillonnage pendant l'entraînement (avec augmentations agressives) attaquerait directement les patients invisibles. C'est l'équivalent d'*Online Hard Example Mining* appliqué côté classe minoritaire.

Modèle 3D natif. Notre 3-slice traite les coupes voisines comme des canaux RGB indépendants, ce qui est une approximation. Un modèle 3D natif (3D ResNet, ou ConvNet 2.5D avec convolution temporelle explicite) capturerait

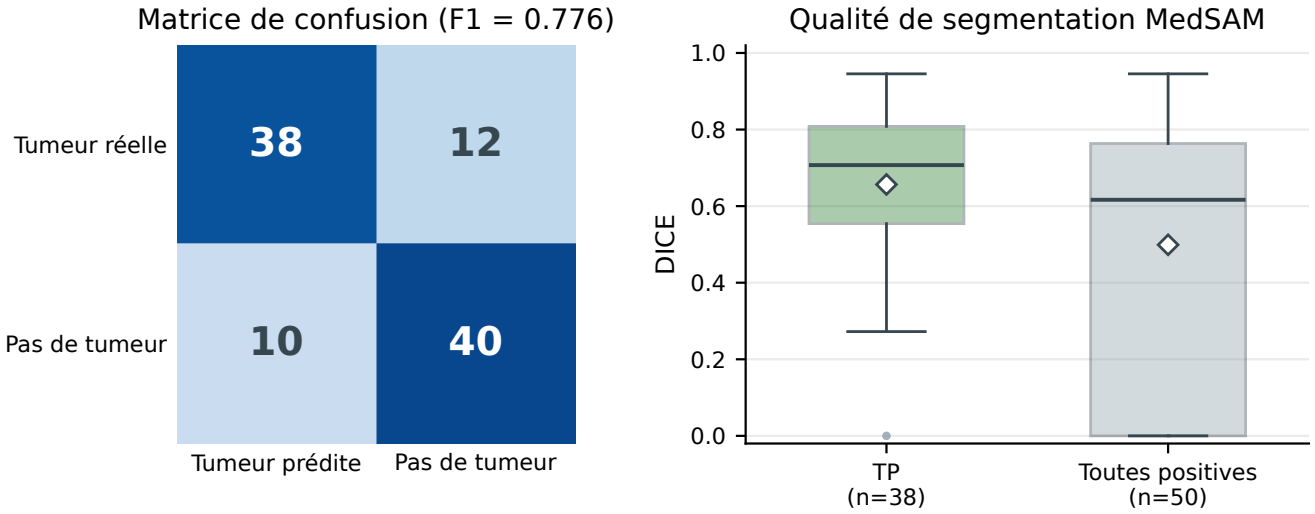

Figure 3: Matrice de confusion et distribution du DICE pour le pipeline final (ResNet-50 + crop=30, 3-slice). À gauche : 38 vrais positifs et 12 faux négatifs sur 50 coupes tumorales, 40 vrais négatifs et 10 faux positifs sur 50 coupes saines. À droite : la qualité de segmentation MedSAM sur les TP est forte (DICE médian supérieur à 0,80), confirmant que *MedSAM* reste un segmenteur fiable dès qu'une boîte plausible lui est fournie. Le DICE moyen sur l'ensemble des coupes positives (incluant les FN à DICE=0) tombe à 0,50 sous l'effet des coupes manquées.

mieux la cohérence entre coupes adjacentes et la continuité géométrique de la lésion. Le coût d'entraînement augmente significativement, mais le bénéfice attendu est important sur les patients dont la tumeur est mieux visible sur la troisième dimension qu'en 2D.

Limites du protocole d'évaluation. Toutes nos métriques sont calculées sur des coupes 2D indépendantes, alors que les tumeurs apparaissent typiquement sur plusieurs coupes adjacentes contrairement aux hallucinations. Une simple agrégation *multi-slice* au moment de la décision finale améliorerait la spécificité sans coût de sensibilité. Par ailleurs, le *split* 50/50 du test a été construit pour faciliter la comparaison entre méthodes, mais ne reflète pas la prévalence clinique réelle des coupes pathologiques (typiquement 5-10 % dans un volume CT). Une évaluation sur une distribution naturelle réévaluerait la valeur pratique de chaque composant, en pénalisant davantage la spécificité.

Reproductibilité et coût. L'ensemble des *checkpoints* (DINO v3, U-Net pancréas, cinq ResNet-50) tient en moins de 2 Go, et l'inférence *end-to-end* sur une coupe prend environ 400 ms sur GPU T4. Le coût total d'entraînement reste sous trois heures de calcul GPU, soit un ordre de grandeur inférieur à celui de *nnU-Net* 3D pour un problème comparable, ce qui rend notre approche adaptée à des déploiements rapides ou à de l'itération méthodologique.

7 Conclusion

Notre projet documente une transition. Sur *Kvasir-SEG*, la chaîne *Grounding DINO+MedSAM* fonctionne pratiquement sans intervention humaine et atteint un DICE oracle de 0,95. Sur *MSD Pancreas*, la même chaîne s'effondre en spécificité (0,18), et seules trois itérations successives d'un classifieur appris en aval — ResNet-18 ensemble, contexte 3-slice, puis ResNet-50 pré-entraîné avec *crop* élargi — restaurent un compromis exploitable de F1=0,78 (sensibilité 0,76, spécificité 0,80, AUC 0,82). Chaque itération était motivée par les distributions de scores observées à l'étape précédente : le 3-slice attaquait le surplus de FP, le ResNet-50 + crop élargi attaquait le déficit de recall sur les tumeurs subtiles. Le plafond résiduel est dicté par un sous-ensemble identifiable de patients (P256, P377, P48) dont les tumeurs sont intrinsèquement hors-distribution pour un classifieur 2D entraîné sur ce volume de données, ce qui ouvre la voie à un encodeur médical pré-entraîné ou à un mining ciblé des positifs rares comme prochaine étape.

Remerciements

Nous remercions les chargés de laboratoire INF8225 pour leurs retours méthodologiques, ainsi que les auteurs de *MedSAM*, *Grounding DINO* et de la base *Medical Segmentation Decathlon* pour la mise à disposition de leurs artefacts.

References

[Antonelli *et al.*, 2022] Michela Antonelli, Annika Reinke, Spyridon Bakas, et al. The Medical Segmentation Decathlon. *Nature Communications*, 13(4128), 2022.

[Caron *et al.*, 2021] Mathilde Caron, Hugo Touvron, Ishan Misra, et al. Emerging properties in self-supervised vision transformers. *International Conference on Computer Vision (ICCV)*, 2021.

[Devlin *et al.*, 2019] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of

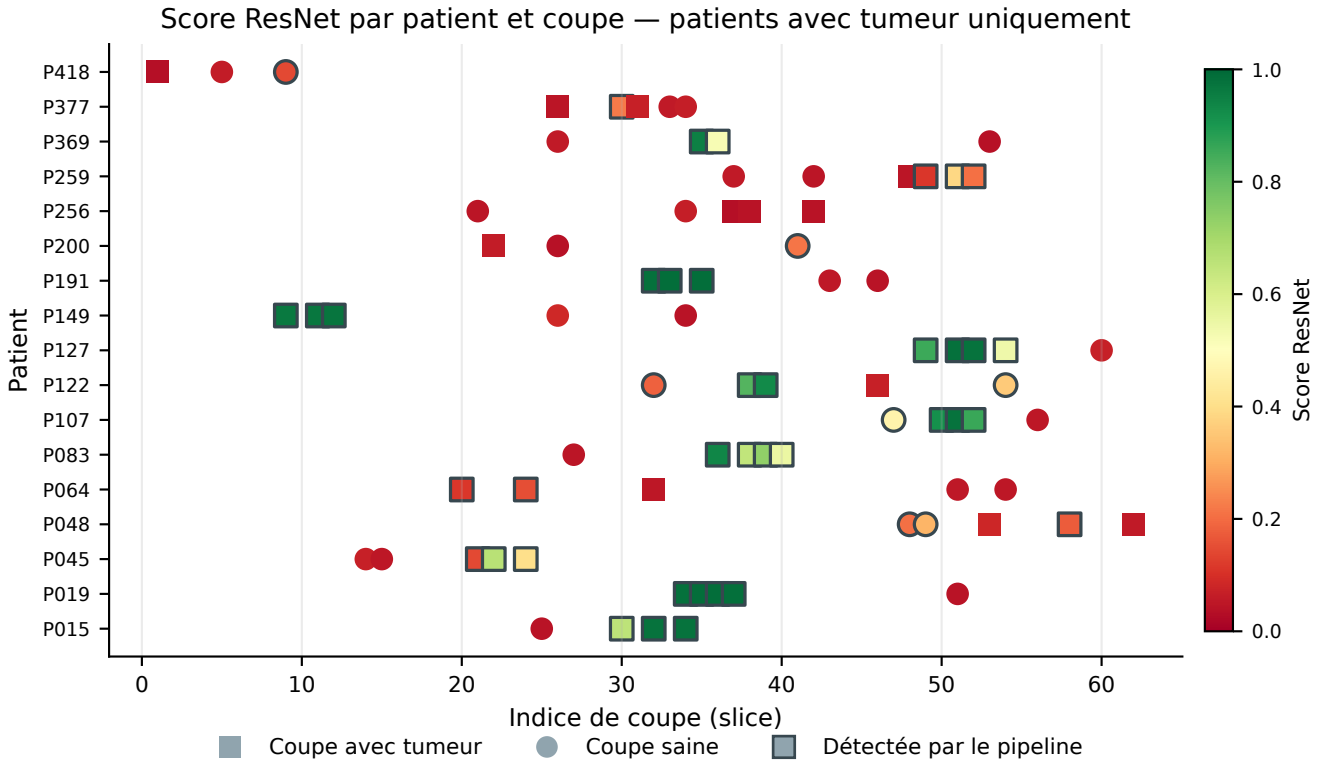

Figure 4: Profil des scores ResNet par patient et par coupe pour les patients tumoraux du test. Carrés = coupes tumorales, ronds = coupes saines, contour épais = détectée par le pipeline. La couleur va du rouge (score faible) au vert (score élevé). La majorité des patients montrent un fort contraste entre coupes tumorales (vertes) et saines (rouges) ; les patients P256, P377 et P48 (FN persistants) ont leurs coupes tumorales rouges, indiscernables des coupes saines, signe que la signature de leur tumeur est hors-distribution pour notre classifieur.

deep bidirectional transformers for language understanding. *Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*, 2019.

[He *et al.*, 2016] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[Isensee *et al.*, 2021] Fabian Isensee, Paul F. Jaeger, Simon A. A. Kohl, Jens Petersen, and Klaus H. Maier-Hein. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, 18(2):203–211, 2021.

[Kirillov *et al.*, 2023] Alexander Kirillov, Eric Mintun, Nikhila Ravi, et al. Segment anything. *International Conference on Computer Vision (ICCV)*, 2023.

[Lin *et al.*, 2017] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. *International Conference on Computer Vision (ICCV)*, pages 2980–2988, 2017.

[Liu *et al.*, 2024] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, et al. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. *European Conference on Computer Vision (ECCV)*, 2024.

[Ma *et al.*, 2024] Jun Ma, Yuting He, Feifei Li, Lin Han, Chenyu You, and Bo Wang. Segment anything in medical images. *Nature Communications*, 15(654), 2024.

[Ronneberger *et al.*, 2015] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional networks for biomedical image segmentation. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241, 2015.

[Salehi *et al.*, 2017] Seyed Sadegh Mohseni Salehi, Deniz Erdogmus, and Ali Gholipour. Tversky loss function for image segmentation using 3D fully convolutional deep networks. *Machine Learning in Medical Imaging (MLMI)*, pages 379–387, 2017.

[Shrivastava *et al.*, 2016] Abhinav Shrivastava, Abhinav Gupta, and Ross Girshick. Training region-based object detectors with online hard example mining. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 761–769, 2016.

[Team, 2024] Gemini Team. Gemini: A family of highly capable multimodal models. *arXiv preprint arXiv:2312.11805*, 2024.

[Wei *et al.*, 2022] Jason Wei, Xuezhi Wang, Dale Schuurmans, et al. Chain-of-thought prompting elicits reasoning

in large language models. *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

[Zhou *et al.*, 2017] Yuyin Zhou, Lingxi Xie, Wei Shen, Yan Wang, Elliot K. Fishman, and Alan L. Yuille. A fixed-point model for pancreas segmentation in abdominal CT scans. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 693–701, 2017.

[Zhu *et al.*, 2019] Zhuotun Zhu, Yongyi Lu, Wei Shen, Elliot K. Fishman, and Alan L. Yuille. Multi-scale coarse-to-fine segmentation for screening pancreatic ductal adenocarcinoma. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 3–12, 2019.